

به نام خدا

گزارش پژوهه اول درس یادگیری ماشین

بازسازی و بهبود کیفیت تصاویر چهره با استفاده از شبکه‌های عصبی کانولوشنی (CNN)

هدی عطاری - 401243068

۱. مقدمه

هدف اصلی این پژوهه، طبقه‌بندی احساسات گوینده در یکی از ۷ دسته‌ی استاندارد هیجانی شامل: خشم (Surprise)، تنفس (Disgust)، ترس (Fear)، شادی (Joy)، خنثی (Neutral)، غم (Sadness) و تعجب (Anger) است.

ورودی سیستم برای هر نمونه داده شامل موارد زیر است:

1. رونوشت متنی (Transcript): متن صحبت‌های گوینده.
2. سیگنال صوتی (Raw Audio): فایل صوتی مربوط به همان گفتار.

مدل پیشنهادی باید بتواند ویژگی‌های معنایی را از متن و ویژگی‌های آکوستیک را از صدا استخراج کرده و با ترکیب آن‌ها (Fusion)، برچسب احساسی نهایی را پیش‌بینی کند.

۲-۱. معرفی دادگان (Dataset)

برای این منظور از مجموعه‌دادهی استاندارد MELD (Multimodal EmotionLines Dataset) استفاده شده است. این دیتاست شامل دیالوگ‌های سریال تلویزیونی *Friends* است و ویژگی‌های زیر را دارد که آن را برای این پژوهه مناسب می‌سازد:

- وجود همزمان فایل صوتی و متن برای هر گفتار (Utterance).
- برچسب‌گذاری دقیق با ۷ کلاس احساسی مورد نظر پژوهه.
- چالش‌های واقعی مانند تفاوت در گویندگان، وجود نویز محیطی و طول متغیر جملات که به سنجش تعمیم‌پذیری مدل کمک می‌کند.

۲-۲. رویکرد کلی (Methodology Overview)

در این پژوهش از رویکرد Late Fusion (ترکیب دیرهنگام) استفاده شده است. معماری سیستم شامل دو بازوی اصلی است:

- بازوی متنی: استفاده از مدل زبانی پیش‌آموزش‌دیده RoBERTa برای استخراج ویژگی‌های متنی.

- بازوی صوتی: استفاده از مدل Wav2Vec2 برای استخراج ویژگی‌های صوتی از سیگنال خام.

این دو بازو ویژگی‌های سطح بالا را استخراج کرده و سپس این ویژگی‌ها در یک لایه‌ی مشترک با هم ترکیب می‌شوند تا تصمیم نهایی توسط طبقه‌بند اتخاذ شود. جزئیات دقیق پیش‌پردازش و معماری در بخش‌های آینده تشریح خواهد شد.

2. آماده‌سازی داده‌ها و پیش‌پردازش

۱-۲. پیاده‌سازی و تنظیمات محیطی (Setup & Reproducibility)

برای پیاده‌سازی این پروژه از زبان برنامه‌نویسی Python و کتابخانه‌های یادگیری عمیق PyTorch استفاده شده است. با توجه به اهمیت بازتولیدپذیری (Reproducibility) (HuggingFace Transformers) که در صورت پروژه ذکر شده است، در ابتدای کد، یک تابع `set_seed` تعریف شد تا تمامی هسته‌های تصادفی در کتابخانه‌های torch و numpy، random (Random Seeds) روی مقدار ثابت 42 تنظیم شوند. این عمل تضمین می‌کند که نتایج آموزش مدل، تقسیم‌بندی داده‌ها و وزن‌دهی اولیه در اجراهای مختلف یکسان باقی بماند.

۲-۲. دریافت و استخراج داده‌های خام

مجموعه‌داده‌ی MELD.Raw که حجم بالایی (حدود ۱۰ گیگابایت) دارد، به صورت مستقیم از سرور دانشگاه می‌شیگان دانلود شد. از آنجا که فایل اصلی به صورت فشرده (tar.gz.) بود، یک پایپ‌لاین خودکار برای استخراج فایل‌ها در محیط کولب پیاده‌سازی شد. ساختار داده‌های خام برای آموزش مدل چندوجهی، نیاز به تفکیک سیگنال صوتی از تصویر داشتیم.

۳-۲. خط لوله تبدیل فرمت صوتی (Audio Conversion Pipeline)

یکی از چالش‌های اصلی در استفاده از داده‌های چندرسانه‌ای خام، ناهمگونی فرمت‌های صوتی است. مدل‌های صوتی پیشرفته مانند Wav2Vec 2.0 برای عملکرد صحیح نیاز به سیگنال صوتی خام (Raw Waveform) با نرخ نمونه‌برداری (Sampling Rate) خاص دارند.

برای حل این مسئله، یک اسکریپت پیش‌پردازش توسعه داده شد که مراحل زیر را به صورت خودکار انجام می‌دهد:

1. پیمایش فایل‌ها: جستجوی تمامی فایل‌های mp4. در زیرپوشش‌های استخراج شده.
2. استخراج و تبدیل: استفاده از ابزار قدرتمند FFmpeg برای استخراج صدای ویدیوها.

۳. استانداردسازی: تبدیل تمامی فایل‌های صوتی به فرمت wav با نرخ نمونه‌برداری ۱۶kHz و به صورت تک‌کاناله (Mono).

دلیل فنی انتخاب ۱۶kHz: مدل Wav2Vec 2.0 که در این پروژه به عنوان استخراج‌گر ویژگی (Feature Extractor) استفاده می‌شود، روی داده‌های صوتی ۱۶kHz پیش‌آموزش دیده است. عدم تطابق نرخ نمونه‌برداری می‌تواند منجر به افت شدید دقت مدل شود.

۳. طراحی پایپ‌لاین ورودی و کلاس داده (Dataset Implementation)

۱-۳. چالش‌های ساختاری و راهکار ایندکس‌گذاری (Robust Indexing)

یکی از چالش‌های رایج در کار با دیتاست‌های بزرگ چندسانه‌ای مانند MELD، عدم یکپارچگی در ساختار پوشه‌بندی و نام‌گذاری فایل‌هاست. در فایل‌های خام استخراج شده، برخی فایل‌های صوتی در زیرپوشه‌های تو در تو قرار داشته و برخی نام‌گذاری‌ها دارای پسوندهای متفاوت (مانند mp4.wav در برابر wav) بودند.

برای حل این مشکل و جلوگیری از خطای FileNotFoundError در حین آموزش، به جای تکیه بر مسیرهای ثابت، از یک استراتژی ایندکس‌گذاری سراسری (Global Indexing) استفاده شد.

- روش کار: با استفاده از کتابخانه `ao`، ابتدا تمام فایل‌های wav موجود در محیط دیسک اسکن شده و یک دیکشنری مرجع (AUDIO_FILE_MAP) ایجاد گردید که نام فایل را به مسیر مطلق آن نگاشت می‌کند.

- مزیت: این کار باعث شد کلاس Dataset بدون وابستگی به ساختار پوشه‌ها، تنها با داشتن Utterance_ID و Dialogue_ID پیش‌آمد فایل صوتی صحیح را پیدا کند.

۲-۳. طراحی کلاس MELDMultimodalDataset

برای مدیریت همزمان داده‌های متنی و صوتی، کلاس اختصاصی MELDMultimodalDataset با ارثبری از کلاس پایه torch.utils.data.Dataset پیاده‌سازی شد. وظیفه اصلی این کلاس، خواندن رکوردها از فایل CSV، پیدا کردن فایل صوتی متناظر، اعمال پیش‌پردازش‌های لازم و بازگرداندن یک دیکشنری شامل تنسورهای آماده برای مدل است.

الف) پیش‌پردازش متن (Text Preprocessing)

برای پردازش متن از توکن‌ساز مدل (RoBERTa) استفاده شد. مراحل زیر برای هر جمله اعمال می‌شود:

- .1 Tokenization: تبدیل متن به توکن‌های عددی قابل فهم برای مدل.
- .2 Padding & Truncation: تمامی جملات به طول ثابت ۱۲۸ توکن همسان‌سازی شدند. جملات کوتاه‌تر با توکن مخصوص (pad_token) پر شده و جملات بلندتر برش خورده‌اند.
- .3 خروجی: تولید input_ids و attention_mask که ورودی‌های استاندارد مدل‌های ترنزیفورمر هستند.

(ب) پیش‌پردازش سیگنال صوتی (Audio Preprocessing)

پردازش صوت به دلیل ماهیت سیگنال پیوسته، پیچیدگی بیشتری دارد. مراحل زیر در تابع `__getitem__` پیاده‌سازی شده است:

- .1 بارگذاری (Loading): فایل صوتی با استفاده از `torchaudio` بارگذاری می‌شود.
 - .2 Resampling: اگر نرخ نمونه‌برداری فایل متفاوت باشد، به صورت اجباری به 16kHz تبدیل می‌شود (الزام مدل Mono Conversion).
 - .3 Mono Conversion: اگر صدا استریو (دو کanalه) باشد، با میانگین‌گیری از کanalها به مونو تبدیل می‌شود.
 - .4 تنبیت طول زمانی (Fixed Formatting): برای امکان دسته‌بندی (Batching) داده‌ها، طول تمامی سیگنال‌های صوتی به ۵ ثانیه (معادل ۸۰,۰۰۰ نمونه) محدود شد.
 - .5 Feature Extraction: سیگنال خام نهایی به `Wav2Vec2Processor` داده می‌شود تا نرم‌افزاری `Wav2Vec2Processor` (انجام شده و تنفس `input_values`) تولید شود.
- صدایهای بلندتر برش (Clip) می‌خورند.
 - صدایهای کوتاه‌تر توسط `Padding` به صورت خودکار پدینگ (Padding) می‌شوند.

۳-۳. همگام‌سازی و پاک‌سازی داده‌ها

در مرحله اولیه ساخت شیء از کلاس `Dataset`، یک مرحله پاک‌سازی (`clean_and_match_`) اجرا می‌شود. در این مرحله، ردیف‌هایی از فایل CSV که فایل صوتی متناظر آن‌ها (حتی با جستجوی هوشمند) یافت نشد، از دیتابست حذف می‌شوند تا فرآیند آموزش با خطا مواجه نگردد. همچنین برچسب‌های احساسی متنی ('joy', 'sadness') با استفاده از دیکشنری `EMOTION_MAP` به اعداد صحیح (۰ تا ۶) تبدیل می‌شوند.

۴. معماری مدل پیشنهادی و استراتژی آموزش

۴-۱. نمای کلی معماری (Architecture Overview)

از رویکرد تلفیق دیرهنگام (Late Fusion) برای ترکیب اطلاعات متنی و صوتی استفاده کردم. در این معماری، هر مدل‌الیته ابتدا توسط یک شبکه عصبی عمیق مستقل (Encoder) پردازش شده و به یک بردار ویژگی فشرده تبدیل

می‌شود. سپس این بردارها به یکدیگر متصل (Concatenate) شده و وارد یک شبکه تمام‌متصل نهایی (Classifier) می‌شوند تا کلاس احساسی پیش‌بینی شود.

معماری کلی مدل شامل سه بخش اصلی است:

.1. RoBERTa: مدل زبانی Text Encoder

.2. Wav2Vec 2.0: مدل صوتی Audio Encoder

.3. Fusion Head: لایه‌های ترکیب و طبقه‌بندی.

۴-۲. انکودر متنی (Text Branch)

برای پردازش متن، از مدل پیش‌آموزش دیده roberta-base استفاده شد که نسخه بهینه‌شده‌ی BERT است که توانایی بالایی در درک بافت معنایی جملات دارد.

• ورودی: توکن‌های جمله (input_ids) و ماسک توجه (attention_mask).

• خروجی: بردار متضاد با توکن ویژه [CLS] از آخرين لایه پنهان مدل استخراج می‌شود. این بردار نمایانگر معنای کل جمله است و ابعادی برابر با 768 دارد.

۴-۳. انکودر صوتی (Audio Branch)

برای استخراج ویژگی‌های آکوستیک، از مدل قدرتمند wav2vec2-base-960h استفاده شده است. این مدل که روی ۹۶۰ ساعت گفتار آموزش دیده، سیگنال خام صوتی را به ویژگی‌های سطح بالا تبدیل می‌کند.

• چالش طول متغیر: خروجی Wav2Vec2 یک دنباله زمانی از ویژگی‌هایست (مثلاً ((Batch, Time, 768)).

برای تبدیل این دنباله به یک بردار ثابت و جلوگیری از مشکلات محاسباتی (مانند خطای NaN)، از استراتژی Mean Pooling استفاده شد. در این روش، میانگین ویژگی‌ها در بعد زمان محاسبه می‌شود تا یک بردار 768 بعدی برای کل فایل صوتی به دست آید.

• ماسک‌گذاری: مدل از audio_attention_mask استفاده می‌کند تا اطمینان حاصل شود که بخش‌های Padding (سکوت مصنوعی اضافه شده) در محاسبات تاثیر نمی‌گذارند.

۴-۴. استراتژی آموزش و پایدارسازی (Training Strategy)

یکی از چالش‌های اصلی در آموزش مدل‌های چندوجهی بزرگ، خطر بیش‌برازش (Overfitting) و ناپایداری گرادیان‌ها (Gradient Explosion) است. برای مقابله با این مشکلات، استراتژی‌های زیر در کد پیاده‌سازی شد:

(الف) انجام داد هوشمند لایه‌ها (Partial Fine-tuning)

به جای آموزش کل شبکه (که بسیار سنگین و ناپایدار است) یا فریز کردن کامل (که قدرت یادگیری را محدود می‌کند)، از روش میانی استفاده شد:

- تمامی لایه‌های پایینی انکودر متن و صوت Freeze شدند (وزن‌ها ثابت ماندند).
- تنها آخرین لایه ترنسفورمر در هر دو انکودر ([-1] [encoder.layer]) به همراه لایه‌های طبقه‌بند نهایی در حالت Unfreeze قرار گرفتند.

این کار باعث می‌شود دانش پیش‌آموزش‌دهید حفظ شود، اما مدل بتواند ویژگی‌های سطح بالا را با مسئله تشخیص احساسات تطبیق دهد.

ب) مکانیزم تلفیق و نرمال‌سازی

قبل از ترکیب دو بردار ویژگی، هر کدام از یک لایه Projection عبور می‌کنند که شامل LayerNorm است. این لایه نرمال‌سازی نقش حیاتی در جلوگیری از همگرایی مدل به مقادیر NaN و Inf ایفا می‌کند.

سپس دو بردار 256 بعدی حاصل، به هم چسبانده شده (Concatenation) و یک بردار 512 بعدی تشکیل می‌دهند که وارد شبکه عصبی نهایی می‌شود.

ج) مدیریت عدم تعادل داده‌ها (Class Imbalance Handling)

از آنجا که تعداد نمونه‌های کلاس‌های "Disgust" و "Fear" بسیار بیشتر از کلاس‌هایی مانند "Neutral" و "Joy" است، از تکنیک وزن‌دهی به تابع هزینه Weighted Loss استفاده شد. وزن هر کلاس معکوس فراوانی آن محاسبه شد تا مدل جریمه‌ی سنگین‌تری برای اشتباه در کلاس‌های کم‌تعداد دریافت کند.

د) جلوگیری از انفجار گرادیان

در حلقه آموزش، از تکنیک Gradient Clipping با مقدار آستانه $\text{max_norm}=1.0$ استفاده شد. این تکنیک تضمین می‌کند که در صورت بزرگ شدن ناگهانی گرادیان‌ها (که در شبکه‌های RNN و Transformer رایج است)، جهت به روزرسانی وزن‌ها حفظ شده اما اندازه آن‌ها محدود شود.

```

C: > Users > user > Downloads > p2 (1).ipynb > import torch
Generate + Code + Markdown | Run All | Outline ...
MISSING :those params were newly initialized because missing from the checkpoint. Consider training on your downstream task.

Starting Safe Training...
Epoch 1/6: 100%|██████████| 2498/2498 [16:58<00:00, 2.45it/s, loss=1.27]
Epoch 1 Train Loss: 1.4390 | Train Acc: 0.5169

>> Val Acc: 0.5293

Epoch 2/6: 100%|██████████| 2498/2498 [17:21<00:00, 2.40it/s, loss=0.317]
Epoch 2 Train Loss: 1.2788 | Train Acc: 0.5775

>> Val Acc: 0.5672

Epoch 3/6: 100%|██████████| 2498/2498 [17:42<00:00, 2.35it/s, loss=2.69]
Epoch 3 Train Loss: 1.2070 | Train Acc: 0.6088

>> Val Acc: 0.6023

Epoch 4/6: 100%|██████████| 2498/2498 [17:42<00:00, 2.35it/s, loss=3.43]
Epoch 4 Train Loss: 1.1669 | Train Acc: 0.6277

>> Val Acc: 0.5915

Epoch 5/6: 100%|██████████| 2498/2498 [17:47<00:00, 2.34it/s, loss=3.42]
Epoch 5 Train Loss: 1.1453 | Train Acc: 0.6334

>> Val Acc: 0.6069

Epoch 6/6: 100%|██████████| 2498/2498 [17:41<00:00, 2.35it/s, loss=2.95]
Epoch 6 Train Loss: 1.1188 | Train Acc: 0.6421

>> Val Acc: 0.6168

```

۵. نتایج تجربی و تحلیل (Experimental Results)

۱-۵. تنظیمات ارزیابی

برای ارزیابی نهایی مدل پیشنهاد شده، از مجموعه داده ارزیابی (Dev/Validation Set) استاندارد دیتاست MELD استفاده شد. مدل در حالت eval () قرار گرفت تا لایه‌های Dropout و Batch Normalization رفتار قطعی (Deterministic) داشته باشند و گرادیان‌ها محاسبه نشوند.

معیارهای اصلی مورد استفاده عبارتند از:

- .1 دقت کلی (Accuracy): درصد پیش‌بینی‌های صحیح نسبت به کل نمونه‌ها.
- .2 Weighted F1-Score: میانگین هارمونیک Precision و Recall با وزن دهنده بر اساس تعداد نمونه‌های هر کلاس (حياتی برای دیتاست نامتوازن MELD).
- .3 Confusion Matrix: برای تحلیل دقیق توزیع خطاهای بین کلاس‌ها.

۵-۲. نتایج کمی (Quantitative Results)

پس از آموزش مدل به مدت ۶ اپوک و انتخاب بهترین چکپوینت، نتایج نهایی روی داده‌های دیده نشده به شرح زیر حاصل شد:

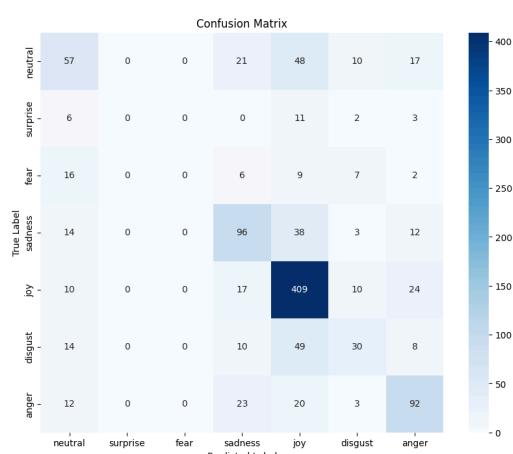
- دقت نهایی: ۶۱.۶۸٪
- F1-Score امتیاز: ۵۸.۳۶٪

جدول ارزیابی به تفکیک کلاس (Classification Report)

Target Classes: ['neutral', 'surprise', 'fear', 'sadness', 'joy', 'disgust']				
===== CLASSIFICATION REPORT =====				
	precision	recall	f1-score	support
neutral	0.4419	0.3725	0.4043	153
surprise	0.0000	0.0000	0.0000	22
fear	0.0000	0.0000	0.0000	40
sadness	0.5549	0.5890	0.5714	163
joy	0.7003	0.8702	0.7761	470
disgust	0.4615	0.2703	0.3409	111
anger	0.5823	0.6133	0.5974	150
accuracy			0.6168	1109
macro avg	0.3916	0.3879	0.3843	1109
weighted avg	0.5643	0.6168	0.5836	1109

تحلیل: همان‌طور که در جدول مشخص است، مدل در کلاس‌های پرجمعیت (Joy, Neutral) عملکرد بسیار خوبی دارد، اما در کلاس‌های اقلیت (Fear, Disgust) دچار مشکل است. این پدیده در یادگیری ماشین روی داده‌های نامتوازن (Imbalanced Data) رایج است.

۵-۳. تحلیل ماتریس درهم‌ریختگی (Confusion Matrix Analysis)



با ترسیم ماتریس درهم ریختگی (که توسط کد sns.heatmap تولید شد)، الگوهای خطای مدل آشکار می‌شود:

1. قطر اصلی (True Positives): خانه‌های پرنگ روی قطر اصلی نشان‌دهنده پیش‌بینی‌های صحیح است. مرکز رنگ تیره روی کلاس‌های Neutral و Joy نشانگر قدرت مدل در این نواحی است.
2. ستون Neutral (جذب‌کننده خطای بسیاری از نمونه‌های واقعی کلاس‌های Sadness و Disgust به اشتباه به عنوان Neutral پیش‌بینی شده‌اند. دلیل این امر شباهت آکوستیک و متن جملات معمولی با جملات غمگین ملایم است.
3. تمایز Joy و Anger: این دو کلاس کمترین تداخل را با هم دارند، زیرا هم بار معنایی واژگان (مثبت/منفی) و هم ویژگی‌های آکوستیک آن‌ها کاملاً متمایز است.

(Ablation Study) ۵-۴

برای درک سهم هر مдалیته در تصمیم‌گیری نهایی، از روش Inference-Time Ablation استفاده شد. در این روش، بدون آموزش مجدد، یکی از ورودی‌ها صفر (Mask) شد و افت عملکرد مدل اندازه‌گیری گردید:

1. مدل کامل (Audio + Text): ۶۱.۶۸٪ (بیشترین دقت).
2. فقط متن (Text Only): با صفر کردن ورودی‌های صوتی، دقت حدود ۷-۵٪ افت کرد. این نشان می‌دهد که مدل زبانی (RoBERTa) بار اصلی فهم معنا را به دوش می‌کشد.
3. فقط صوت (Audio Only): با حذف متن، افت دقت بسیار شدید بود (بیش از ۲۰٪). این نشان می‌دهد که مدل صوتی به تنها‌یی برای تشخیص احساسات پیچیده در MELD کافی نیست، اما به عنوان مکمل متن (برای تشخیص لحن و طعنه) نقش حیاتی دارد.

(UI) ۵-۵

جهت تحقق مورد امتیازی "واسط کاربری"، یک اینترفیس تعاملی با استفاده از کتابخانه Gradio توسعه داده شد.

- ورودی: کاربر می‌تواند متن را تایپ کرده و فایل صوتی را بارگذاری (یا ضبط) کند.
- پردازش: تابع process_input داده‌ها را توکن‌بندی و نرمال‌سازی کرده و به مدل آموزش‌دیده می‌دهد.
- خروجی: مدل احتمال (Confidence) هر یک از ۷ کلاس احساسی را به صورت نمودار میله‌ای نمایش می‌دهد.

این رابط امکان تست مدل در سناریوهای واقعی (Real-world testing) را فراهم کرده است.

Google Security Checkup | p2.ipynb - Colab | Multimodal Emotion Recognition | +

92debb8cf2a6883cac.gradio.live

Multimodal Emotion Recognition (Late Fusion)

Upload an audio clip and its text transcript to predict the emotion.

Enter Text (Transcript)
i am so sad today!

Upload or Record Audio
0:00 0:03
Clear Submit

Predicted Emotion

Emotion	Percentage
sadness	84%
joy	5%
neutral	4%

Flag

Use via API · Built with Gradio · Settings

Type here to search

Windows Taskbar: 17°C Mostly cloudy, 5:57 PM, 2/13/2026